



ICAN Lab
資訊與通訊系統架構實驗室

應用知識圖注意力網路於食譜推薦之 效能評估與可解釋性研究

Performance Evaluation and Explainability Study of KGAT for Recipe Recommendation

研究生：廖健合 (指導教授：張瑞益教授)

國立臺灣大學工程科學及海洋工程學系碩士論文口試

簡報大綱 (Outline)

1. 研究背景與缺口

- ▶ 食譜平台資訊過載與 CF 限制
- ▶ 傳統推薦模型演進與對比
- ▶ 既有 KGAT 研究之三大缺口

2. 研究問題與核心架構

- ▶ 三大核心研究問題 (RQ1 ~ RQ3)
- ▶ CKG 建構與超級節點修剪
- ▶ KGAT 四階段視覺化架構與公式

3. 推薦效能與消融實驗 (RQ1 / RQ2)

- ▶ 評估協定與 Food.com 720 萬邊 Profile
- ▶ 主要推薦效能結果 (超越 Base +31.6%)
- ▶ 淺層 KG「資訊污染」現象 (消融高光)
- ▶ 訓練動態與 Early Stopping 必要性

4. 可解釋性 Fidelity 評估 (RQ3)

- ▶ 邊擾動評估架構 (F^+ 必要性 / F^- 充分性)
- ▶ 500 位使用者 Fidelity 採樣統計
- ▶ 三大路徑類型 Fidelity 分析與 Case C

食譜平台的資訊過載需要更有依據的推薦

背景與痛點

- ▶ 食譜平台累積海量食譜、食材、標籤與使用者互動。
- ▶ 使用者面臨資訊過載，難以快速找到符合偏好的食譜。
- ▶ **傳統協同過濾 (CF)**：僅依賴歷史互動，面臨資料稀疏與冷啟動限制。

核心研究問題

如何有效利用食材與標籤等輔助知識，產生高準確且可說明的推薦結果？

轉場點：知識圖譜 (KG) 提供了豐富語意關係，但其真實效益與注意力解釋的可信度不能被直接假定。

推薦模型演進與對比：由協同過濾到圖注意力網路

模型類別	代表方法	優勢 (Advantages)	局限性 (Limitations) / 本文缺口
矩陣分解 (CF)	BPR-MF	運算簡單，有效擬合高頻互動。	無法利用食材/標籤等富語意輔助資訊，冷啟動能力差。
特徵互動 (FM)	NFM	透過神經網路捕捉非線性高階特徵互動。	將實體視為獨立特徵，無法利用多跳圖拓樸關聯。
圖卷積 (GNN)	LightGCN	簡化 GNN，在二分圖上高效傳播協同訊號。	僅處理使用者-物品單一關係，忽視 KG 中異質關係差異。
圖注意力 (KGAT)	KGAT (本文研究)	整合 CKG、關係感知注意力與多跳傳播。	既有研究缺乏食譜場景實證、逐層消融與 Fidelity 忠實度量化。

KGAT 的潛力，也帶出三個尚未回答的問題

- ▶ **協同知識圖譜 (CKG)**：將使用者-食譜互動與食譜屬性（食材、標籤）統一建構為 CKG。
- ▶ **KGAT 特點**：透過關係感知注意力機制 (Relation-aware Attention) 與多跳傳播，擷取高階語意關聯。

既有研究的三大缺口 (Research Gaps)

1. **食譜領域驗證**：KGAT 缺乏在大規模真實食譜場景 (Food.com) 的深度實證。
2. **逐層機制剖析**：缺乏對不同傳播深度 ($1L/2L/3L$) 與輔助資訊增益的深入消融分析。
3. **解釋真實性質疑**：注意力權重路徑是否忠實 (Fidelity) 反映模型的真正決策？

本研究以三個 RQ 收斂問題

RQ1: 推薦效能

傳播深度與 KG 輔助資訊整合，如何影響食譜推薦效能？

RQ2: 訓練行為

不同傳播深度下，訓練行為、收斂速度與泛化能力有何差異？

RQ3: 可解釋忠實度

模型的注意力路徑是否忠實 (Fidelity) 反映其決策依據？

遞進邏輯：效能驗證 (RQ1) → 訓練機制解構 (RQ2) → 解釋真實性檢驗 (RQ3)

本研究的貢獻是效能、機制與解釋三層驗證

► 貢獻 1：食譜領域大規模實證

- 在 Food.com 實作 CKG，進行 KGAT-1L/2L/3L 與基線模型 (BPR-MF, NFM, LightGCN) 的嚴謹對比。

► 貢獻 2：揭露淺層 KG 的「資訊污染」機制

- 發現單跳傳播下引入 KG 輔助資訊反而可能稀釋協同過濾訊號，釐清深度整合與超級節點修剪的必要性。

► 貢獻 3：建立注意力路徑 Fidelity 評估管線

- 提出邊擾動測試檢驗路徑必要性 (F^+) 與充分性 (F^-)，跨深度與路徑類型評估解釋的真實忠實度。

CKG 將互動與食譜語意放進同一張圖 (Data Profile 對齊)

圖譜結構與超級節點修剪


- ▶ 節點種類：User, Recipe, Ingredient, Tag。
- ▶ 關係類型：interact, has_ingredient, has_tag 及反向邊/自迴圈邊。
- ▶ 超級節點修剪 (Super-node Pruning)：
 - ▶ 移除出現頻率前 0.5% (74 個) 高頻食材與 13 個通用食材 (如 salt, water, oil, sugar)。
 - ▶ 移除出現頻率前 50 個熱門標籤 (如 easy, dinner)。

Food.com CKG 統計數據 (表 4.1)

- ▶ 使用者數：226,570
- ▶ 食譜數：231,637
- ▶ 歷史互動數：1,132,367
- ▶ 修剪後 KG 屬性實體：15,370
- ▶ 修剪後 KG 三元組：2,230,927
- ▶ CKG 總節點數：473,577
- ▶ CKG 總邊數：7,200,165

KGAT 四階段視覺化架構與訊息傳播公式

高階視覺化流程



1. 關係感知注意力 (Relation-aware Attention)

$$\pi(h, r, t) = \text{Softmax}(W_r t \cdot \tanh(W_r h + e_r))$$

2. 雙重互動聚合 (Bi-Interaction Aggregation)

$$e_h^{(l)} = \text{LeakyReLU} \left(W_1^{(l)} (e_h^{(l-1)} + e_{N_h}^{(l)}) + W_2^{(l)} (e_h^{(l-1)} \odot e_{N_h}^{(l)}) \right)$$

3. 跨層拼接與偏好預測 (JK Pooling)

$$e_u^* = e_u^{(0)} \parallel e_u^{(1)} \parallel \dots \parallel e_u^{(L)}, \quad \hat{y}(u, i) = e_u^{*T} e_i^*$$

評估設計與超參數設定 (確保實驗可重現性)

評估協定 (Evaluation Setup)

- ▶ 切分方式：Leave-one-out 留一法。
- ▶ 負樣本：每筆正樣本搭配 100 個未互動食譜。
- ▶ 評估指標：HR@K, NDCG@K, Precision@K ($K = 10, 20, 50$)。
- ▶ 重複實驗：每個模型獨立執行 3 次，報告平均值。

統一超參數與硬體設定

- ▶ 嵌入維度： $d = 64$ | **Batch Size**：1,024
- ▶ 學習率： $\eta = 0.001$ (Adam), StepLR 衰減
- ▶ 硬體與精度：Intel Arc A750 GPU (XPU), BFloat16 混合精度訓練。
- ▶ 基線模型：BPR-MF, NFM, LightGCN。

KGAT-3L 於所有主要指標上顯著優於 Baseline (表 4.3)

Table: Food.com 資料集上各模型之推薦效能對比 (三次獨立運行平均值)

模型	HR@10	HR@20	NDCG@10	NDCG@20	Prec@10	Prec@20
BPR-MF	0.4683	0.5830	0.3066	0.3355	0.0468	0.0291
NFM	0.5108	0.6313	0.3408	0.3712	0.0511	0.0316
LightGCN (最速強基線)	0.5320	0.6668	0.3495	0.3836	0.0532	0.0333
KGAT ($L = 1$)	0.5483	0.6761	0.3426	0.3749	0.0548	0.0338
KGAT ($L = 2$)	0.6219	0.7711	0.4005	0.4383	0.0622	0.0386
KGAT ($L = 3$) (本文方法)	0.7348	0.8775	0.4946	0.5309	0.0735	0.0439

關鍵數據摘要 (相對最佳 Baseline LightGCN 之提升)

HR@20: **+31.6%** (0.6668 → 0.8775) | NDCG@20: **+38.4%** (0.3836 → 0.5309) |
Prec@20: **+31.8%**

效能隨深度增加而一致提升 ($L = 1 \rightarrow 2 \rightarrow 3$)

深度對比 (以 $L = 1$ 為基準提升)

- ▶ **KGAT** ($L = 1$) : HR@20 = 0.6761, NDCG@20 = 0.3749
- ▶ **KGAT** ($L = 2$) : HR@20 = 0.7711 (+14.1%), NDCG@20 = 0.4383 (+16.9%)
- ▶ **KGAT** ($L = 3$) : HR@20 = **0.8775** (+29.8%), NDCG@20 = **0.5309** (+41.6%)

實證結論

在 Food.com 的實驗設定下，多跳 (Multi-hop) 知識圖譜傳播展現了顯著且一致的效能累積增益。

多跳傳播成功整合「使用者 → 食譜 → 食材/標籤 → 推薦食譜」的高階拓樸關聯。

消融實驗高光：在淺層架構中，加入 KG 反而可能造成「資訊污染」

消融實驗 ($L = 1$ 深度配置對比)

- ▶ **Full KGAT-1L** (完整模型) :
HR@20 = 0.6761, NDCG@20 = 0.3749
- ▶ **w/o KG-1L** (移除 KG, 退化為純 CF) :
HR@20 = **0.7076 (+4.7%)**, NDCG@20 = **0.4114 (+9.7%)**

發現：淺層 KG 資訊污染 (Information Pollution)

在單跳傳播時，常見食材/標籤等高連接度屬性將過度泛化的特徵灌注至食譜中，雜訊超越資訊增益，稀釋了協同過濾訊號！

學術連結：呼應 *Zhang et al. (2025)* 關於「知識圖對推薦系統之貢獻非無條件正面」的實證觀察。

深層模型極早到達峰值，更需配合 Early Stopping

Table: 不同深度模型前五個 Epoch 之 HR@20 演變趨勢

模型	Epoch 1	Epoch 2	Epoch 3	Epoch 4	Epoch 5	收斂行為判讀
KGAT ($L = 1$)	0.6686	0.6690	0.6731	0.6728	0.6734	緩慢平穩上升
KGAT ($L = 2$)	0.7711	0.7645	0.7522	0.7455	0.7439	Epoch 1 達峰值後遞減
KGAT ($L = 3$)	0.8682	0.8696	0.8644	0.8496	0.8427	Epoch 1-2 達峰值後遞減

訓練機制結論

深層感受野帶來極快的高階結構特徵學習能力，但較大參數空間也使其容易在後續 Epoch 出現測試效能衰退，凸顯了早停機制 (Early Stopping) 的重要性。

路徑要成為解釋，必須通過必要性與充分性雙重檢驗

自關係感知注意力萃取 Top-3 高權重路徑，進行 ** 邊擾動測試 (Edge Perturbation)**：

1. 必要性 F^+ (Fidelity-plus)

從 CKG 中**移除**解釋路徑，觀察預測機率下降程度：

$$F^+ = p(u, i) - p(u, i \setminus \mathcal{P})$$

$F^+ > 0$ 代表該路徑為決策的必要條件。

2. 充分性 F^- (Fidelity-minus)

遮蔽其餘邊，**僅保留**解釋路徑，觀察預測維持程度：

$$F^- = p(u, i) - p(u, i|_{\mathcal{P}})$$

$F^- \approx 0$ 代表該路徑本身即具充分資訊。

深度顯著擴大可解釋路徑覆蓋率 (500 位使用者採樣)

Table: 不同傳播深度下之路徑覆蓋率與 Fidelity 數據 (500 位使用者採樣)

模型	有效路徑人數	路徑覆蓋率	總萃取路徑數	平均 F^+ (必要性 $\uparrow$)	平均 F^- (充
KGAT-1L	5	1.0%	5	0.0247	-0.0002 *(樣
KGAT-2L	230	46.0%	446	0.0644	0.130
KGAT-3L	278	55.6%	488	0.0351	0.0867 (中位

關鍵判讀

- ▶ **覆蓋率**：多跳傳播使 3L 覆蓋率達 **55.6%** (278/500)，遠高於 1L (1.0%)。
- ▶ **整體忠實度**：KGAT-3L 中 **94.2%** (262/278) 使用者 $F^+ > 0$ ，證實注意力權重標記了正向必要貢獻。

解釋品質取決於路徑類型：直接與協同路徑顯著較可靠

Table: KGAT-3L 不同路徑結構類型之 Fidelity 量化對比 (表 4.10)

路徑類型	結構說明	路徑數 n	Avg F^+ ($\uparrow$)	Avg F^- ($\downarrow$)	忠實度評
直接連接	User $\rightarrow$ Recipe	84 (17.2%)	0.0494	-0.0004	最佳忠實
協同過濾	User $\rightarrow$ Rec $\rightarrow$ User $\rightarrow$ Rec	218 (44.7%)	0.0349	0.0134	良好忠實
KG 語意	User $\rightarrow$ Rec $\rightarrow$ Entity $\rightarrow$ Rec	186 (38.1%)	0.0223	0.2449	部分忠實

重大發現：KG 語意路徑充分性偏低 ($F^- = 0.2449$)

「僅保留 KG 語意路徑」會造成約 24.5% 的預測機率損失，表明高階語意經過多層傳播後已高度壓縮進分散式嵌入中，顯式路徑無法單獨涵蓋完整決策。

個案說明 (Case C)：語意直觀不等於模型真實決策依據

論文真實 Case C (User 963993)

- ▶ **推薦食譜**：fantastic tropical thai chicken salad (預測機率 0.933)。
- ▶ **萃取語意路徑**：User → 歷史食譜 → 共同食材 chicken → 推薦食譜。
- ▶ **直觀感受**：極度合理 (兩道食譜均含有「雞肉」)。

Fidelity 實測數據

- ▶ $F^+ = -0.001$ (移除此路徑預測不降反微升)
- ▶ $F^- = 0.5415$ (僅保留路徑損失 54% 機率)

案例啟示

移除「雞肉」語意路徑對預測幾乎無影響 ($F^+ \approx 0$)，僅留此路徑時預測大幅崩塌 (F^- 高)。證實「直觀語意合理 $\neq$ 忠實反映模型內部決策」，展現批判性思考。

結論：深度提升效能與路徑覆蓋，但 KG 與注意力需審慎驗證

1. **效能層面 (RQ1)**：KGAT-3L 在 Food.com 食譜推薦上取得優於 LightGCN 的表現 (**HR@20 +31.6%**, **NDCG@20 +38.4%**)。
2. **機制層面 (RQ2)**：揭露淺層 KG 整合可能造成資訊污染 ($L = 1$ w/o KG $0.7076 > \text{Full } 0.6761$)；深層模型收斂極快且更需 Early Stopping。
3. **解釋層面 (RQ3)**：深層模型顯著提升解釋路徑覆蓋率 (55.6%)；但 Fidelity 證實直連與協同路徑高忠實，KG 語意路徑充分性偏低。

核心主張：可解釋推薦系統應同時進行「**推薦準確度**」與「**解釋忠實度 (Fidelity)**」的雙重驗證。

研究限制與未來展望 (對齊論文 5.3 節)

研究限制 (Limitations)

- ▶ 單一 Food.com 資料集實證。
- ▶ 留一法 100 負樣本與 Full-ranking 有別。
- ▶ 邊遮罩式 Fidelity 可能面臨圖結構分佈偏移 (Distribution Shift) 影響。

未來展望 (Future Work)

- ▶ 探究圖資訊瓶頸 (**GIB**) 機制：解析 KG 語意路徑充分性偏低之隱藏嵌入壓縮效應。
- ▶ 跨領域多資料集驗證與統計顯著性檢定。
- ▶ 引入重訓練與反事實 **Fidelity** 評估管線。

簡報結束，敬請指教

多跳 KGAT 顯著提升推薦效能；可信解釋仍需以 Fidelity 驗證

研究生：廖健合 | 指導教授：張瑞益教授

國立臺灣大學工程科學及海洋工程學系 ICAN Lab

Backup A: 完整 9 指標對比數據 (表 4.3 完整表格)

模型	HR@10	HR@20	HR@50	NDCG@10	NDCG@20	NDCG@50	P@10	P@20
BPR-MF	0.4683	0.5830	0.7416	0.3066	0.3355	0.3670	0.0468	0.0291
NFM	0.5108	0.6313	0.7946	0.3408	0.3712	0.4037	0.0511	0.0316
LightGCN	0.5320	0.6668	0.8516	0.3495	0.3836	0.4203	0.0532	0.0333
KGAT-1L	0.5483	0.6761	0.8366	0.3426	0.3749	0.4068	0.0548	0.0338
KGAT-2L	0.6219	0.7711	0.9464	0.4005	0.4383	0.4735	0.0622	0.0386
KGAT-3L	0.7348	0.8775	0.9830	0.4946	0.5309	0.5524	0.0735	0.0439

Backup B: CKG 超級節點修剪細節

- ▶ **高頻食材修剪**：過濾前 0.5% 出現頻率最高之 74 個食材及 13 個通用調味料 (如 salt, water, oil, sugar, eggs)，避免全圖無差別高度連接。
- ▶ **標籤過濾**：移除前 50 個過度泛化標籤 (如 easy, dinner, preparation)。
- ▶ **實證效果**：防止超級節點成為資訊傳播匯流點，大幅降噪並避免圖神經網路之過度平滑現象。

Backup C: KGAT 損失函數與細節

BPR Loss 結合 L2 正則化：

$$\mathcal{L}_{\text{KGAT}} = \sum_{(u,i,j) \in \mathcal{O}} -\ln \sigma(\hat{y}(u,i) - \hat{y}(u,j)) + \lambda \|\Theta\|_2^2$$

其中正樣本對為 (u,i) ，負採樣樣本為 (u,j) ， $\lambda = 10^{-5}$ 。

Backup D: 其餘案例 (Case A & B)

- ▶ **Case A (Direct Link, User 2410864)** : $F^+ = 0.2415, F^- = 0.0004$ 。展現極高之必要性與充分性 (移除該邊預測降 24%) 。
- ▶ **Case B (CF Path, User 573230)** : $F^+ = 0.2061, F^- = 0.0019$ 。協同過濾長路徑同樣展現高忠實度 ($F^+ > 0.20$) 。

分佈偏移 (Distribution Shift)

當從圖中直接移除邊 (F^+) 或僅保留子圖 (F^-) 時，輸入特徵圖之拓樸結構發生突變，可能使模型進入訓練時未曾見過的狀態，導致 F^- 評估出現偏高誤差 (即 KG 語意路徑 $F^- = 0.2449$ 可能部分來自模型適應不良)。未來宜結合重訓練式或反事實評估。